INSTITUTO PROFESIONAL DUOC UC - SEDE CONCEPCIÓN
ESCUELA DE INFORMATICA & TELECOMUNICACIONES
CARRERA INGENIERÍA EN INFORMÁTICA

Informe Técnico
Machine Learning

Profesora Jazna Meza

Integrantes:

- Diego Améstica
- Gino Andrades
- Agustín Cáceres

Descripción del problema de negocio

En un catálogo musical amplio como el representado en Spotify Tracks, identificar canciones con mayor popularidad y comprender sus características puede apoyar decisiones de selección, promoción y organización del contenido. Sin embargo, revisar cada canción de forma individual resulta poco práctico, y ninguna característica musical permite asegurar por sí sola que una canción será popular. El problema consiste en determinar hasta qué punto los datos disponibles permiten estimar esa popularidad y reconocer patrones que sean útiles para orientar estas decisiones.

El proyecto aborda este desafío desde tres perspectivas complementarias. La regresión busca estimar el puntaje de popularidad de cada canción; la clasificación permite distinguir niveles de popularidad baja, media y alta; y la segmentación agrupa canciones con características acústicas similares. Estos enfoques permiten combinar una estimación numérica, una categoría fácil de interpretar y un perfil musical que aporte contexto al análisis del catálogo.

El alcance del trabajo es evaluar esta capacidad sobre la popularidad registrada en el dataset. Los datos no permiten demostrar que una campaña aumentará las reproducciones ni garantizar el éxito futuro de un lanzamiento. Además, la popularidad puede depender de factores no incluidos, como la promoción, la exposición en playlists, la trayectoria del artista y las tendencias del momento. Por ello, los resultados se plantean como apoyo para tomar decisiones, sin considerar la popularidad como una medida de calidad artística.

Objetivos del proyecto

El objetivo general es desarrollar y comparar modelos de aprendizaje automático que permitan estimar y clasificar la popularidad de canciones de Spotify, complementando sus resultados con una segmentación de perfiles musicales. Se busca identificar qué alternativas ofrecen el mejor desempeño y explicar su utilidad y sus limitaciones para apoyar la selección y el análisis del catálogo.

Para cumplir este objetivo, se utilizará la preparación y el análisis exploratorio realizados previamente como base del modelado. Se revisará la calidad de los datos, el tratamiento de duplicados y valores faltantes, la conservación de outliers válidos y la preparación de variables según las necesidades de cada algoritmo. En los modelos supervisados, se mantendrá la separación entre entrenamiento y prueba para evaluar su desempeño con canciones que no participaron en el aprendizaje.

En clasificación, se compararon Decision Tree y Random Forest, tanto en sus versiones base como optimizadas, prestando especial atención a la detección de canciones de alta popularidad. En regresión, se compararon Decision Tree e HistGradientBoosting para determinar cuál estima el puntaje de popularidad con menor error. En ambos casos, se

analizará si la optimización mejora los resultados y reduce la diferencia entre entrenamiento y prueba.

En aprendizaje no supervisado, se aplicará K-Means para reconocer grupos de canciones con perfiles acústicos similares y describir sus posibles aplicaciones en la organización de playlists y exploración del catálogo. Finalmente, se interpretarán los resultados considerando el desbalance de clases, los errores de predicción y el riesgo de favorecer únicamente los estilos que ya presentan mayor popularidad o representación en los datos.

Definición de KPIs

Los KPIs del proyecto permitirán cuantificar la calidad de las predicciones y la utilidad analítica de los segmentos. Estos indicadores muestran cuánto aporta la solución al problema planteado.

El KPI principal de clasificación será la tasa de detección de canciones de popularidad alta, medida mediante recall. Se calcula dividiendo las canciones altas correctamente identificadas entre todas las canciones realmente altas del conjunto de prueba. Su propósito es medir cuántas oportunidades logra recuperar el modelo.

En regresión, el KPI principal será el error absoluto medio, o MAE, expresado en puntos de popularidad. Este indicador muestra cuánto se alejan, en promedio, las estimaciones de los valores reales; por lo tanto, se buscará reducirlo. Se complementará con R^2, que permite evaluar qué proporción de la variación de popularidad logra explicar el modelo.

Para la segmentación se utilizará el coeficiente de silhouette, que mide qué tan similares son las canciones dentro de su grupo en comparación con otros grupos. Se complementará con la cantidad y el porcentaje de canciones de cada segmento, para comprobar su representatividad.

Área	KPI
Clasificación	**Recall de popularidad alta:** Medir proporción de canciones realmente altas que logra detectar.
Regresión	**MAE:** Medir el error promedio en puntos de popularidad.
Segmentación	**Coeficiente de silhoutte:** Medir la separación y cohesión de los grupos de canciones.

Descripción de las fuentes de datos utilizadas

La fuente de datos utilizada corresponde a Spotify Tracks Dataset, un archivo CSV que contiene inicialmente 114.000 registros y 21 columnas con información descriptiva y musical de las canciones. Incluye identificadores, nombres de artistas, álbumes, géneros y características como duración, bailabilidad, energía, volumen y tempo. La variable principal del proyecto es popularity, cuyo puntaje va de 0 a 100 y se utiliza para estimar la popularidad mediante regresión y definir sus categorías en clasificación. Para la segmentación, se emplean características acústicas para descubrir grupos de canciones similares. Los tres enfoques trabajan sobre esta misma fuente, con una preparación ajustada a cada técnica.

Preparación y análisis exploratorio de los datos (EDA)

La preparación de los datos comenzó con la revisión de las 114.000 observaciones originales, sus tipos de variables, valores faltantes y registros repetidos. Se conservaron 89.741 canciones únicas después de eliminar las repeticiones por track_id, manteniendo la primera aparición de cada canción. Esta decisión evita que una misma pista tenga mayor peso en el análisis o aparezca simultáneamente en entrenamiento y prueba. Sin embargo, también implica conservar una sola etiqueta de género cuando una canción estaba registrada en varios géneros. La columna Unnamed: 0 se excluyó porque corresponde a un índice del archivo.

El análisis exploratorio permitió reconocer diferencias importantes entre las características musicales. Variables como duración, presencia de habla e instrumentalidad presentan distribuciones asimétricas y valores extremos. Estos outliers se conservaron en los trabajos de modelado porque una canción muy larga, instrumental o con características poco habituales no representa necesariamente un error. También se observaron asociaciones individuales débiles entre las características acústicas y la popularidad, lo que motivó evaluar modelos que combinan varias variables. La característica energy se excluyó por una decisión del equipo basada en su relación con otras variables, especialmente loudness y acousticness.

Para clasificación, el puntaje de popularidad se transformó en tres categorías: baja, de 0 a 24; media, de 25 a 49; y alta, de 50 a 100 para conservar el “mejor” balance de clases posible. También se realizó un experimento binario como referencia exploratoria. El puntaje original y las categorías objetivo se excluyeron de los predictores para impedir que el modelo tuviera acceso a la respuesta. Se utilizó una división de 80 % para entrenamiento y 20 % para prueba, manteniendo las proporciones de cada clase mediante estratificación. Como la categoría alta contiene menos canciones, se consideró el desbalance mediante evaluación por clase, F1 y, en el Random Forest optimizado, pesos de clase que dan mayor importancia a las categorías menos numerosas.

Los modelos de clasificación conservaron las variables numéricas en su escala original, ya que los árboles realizan divisiones mediante umbrales y no requieren estandarización. En el experimento de tres categorías, track_genre, key y time_signature se transformaron mediante OneHotEncoder para obtener una representación numérica sin introducir un orden artificial. explicit y mode se mantuvieron directamente porque ya son variables binarias. Los nulos detectados en nombres de artistas, álbumes y canciones no llegaron al modelo, dado que esas columnas fueron excluidas del conjunto predictor.

Para regresión, se mantuvo popularity como un valor numérico entre 0 y 100, porque el objetivo es estimar el puntaje y no asignar una categoría. Se utilizaron características acústicas y variables categóricas, conservando los outliers y sin estandarizar las numéricas, ya que tanto Decision Tree como HistGradientBoosting se basan en árboles. El pipeline incorporó imputación preventiva mediante la mediana para variables numéricas y el valor más frecuente para categóricas. Después, las categóricas se transformaron con OneHotEncoder. Estas medidas permiten manejar eventuales valores faltantes y categorías nuevas sin alterar el enfoque del experimento. Los datos también se dividieron en 80 % para entrenamiento y 20 % para prueba.

Para segmentación, la preparación fue diferente porque K-Means agrupa canciones según la distancia entre sus características. Se seleccionaron nueve variables numéricas que describen su perfil acústico y duración. La popularidad y el género se excluyeron de la formación de los grupos y se utilizaron posteriormente para describirlos. De esta manera, los segmentos surgieron de las similitudes musicales, sin estar definidos previamente por niveles de popularidad o etiquetas de género. También se excluyeron las demás variables categóricas para mantener ese enfoque.

En K-Means se incorporó imputación preventiva por mediana y estandarización mediante StandardScaler. Este escalamiento evita que una variable como la duración en milisegundos domine las distancias frente a características cuyos valores están entre 0 y 1. Los outliers permanecieron presentes después de la transformación, por lo que se revisó su concentración en los segmentos para interpretar con cautela los grupos más influenciados por extremos. A diferencia de los modelos supervisados, la segmentación se realizó sobre el conjunto preparado completo, con el propósito de descubrir perfiles dentro del catálogo disponible.

En clasificación y regresión, las transformaciones se ajustaron utilizando únicamente los datos de entrenamiento y, durante la búsqueda de hiperparámetros, dentro de los pipelines de validación. Así se evitó utilizar información del conjunto de prueba para preparar o seleccionar los modelos. En conjunto, la preparación mantuvo una base común de canciones, pero adaptó el tratamiento de las variables a la forma en que cada técnica aprende y al objetivo que debía resolver.

Metodología utilizada (CRISP-DM)

El proyecto se desarrolló siguiendo la metodología CRISP-DM, que organiza el trabajo de ciencia de datos en seis fases: comprensión del negocio, comprensión de los datos, preparación, modelado, evaluación y despliegue. Estas etapas orientaron el análisis de popularidad de las canciones de Spotify mediante clasificación, regresión y segmentación.

Comprensión del negocio. Se definió el problema como la predicción de popularidad de canciones a partir de sus características musicales y género. Como aplicación, se propuso apoyar la selección y el análisis del catálogo. La clasificación se enfocó en detectar canciones realmente pertenecientes al grupo de popularidad alta; la regresión, en estimar su puntaje; y la segmentación, en descubrir perfiles musicales similares.También se reconoció que popularidad no equivale a calidad artística y que los datos disponibles no permiten demostrar un aumento de reproducciones.

Comprensión de los datos. Se examinó la estructura del dataset, compuesto inicialmente por 114.000 registros y 21 columnas. Se revisaron tipos de variables, valores faltantes, canciones repetidas, distribuciones y outliers y visualizaciones. Las correlaciones permitieron explorar asociaciones entre características y popularidad, además de identificar variables relacionadas entre sí. Esta fase mostró que las características musicales presentan comportamientos diversos y que sus asociaciones individuales con popularidad son débiles, lo que motivó evaluar modelos que combinan varias variables.

Preparación de los datos. Se eliminaron las repeticiones por track_id, obteniendo 89.741 canciones únicas, y se excluyeron índices, nombres e identificadores del conjunto de predictores. Se conservaron los outliers y se adaptó el procesamiento a cada técnica. En clasificación se crearon categorías de popularidad y se aplicó codificación a las variables nominales, manteniendo las numéricas sin escalamiento. En regresión se conservó el puntaje original como objetivo y se incorporaron imputación preventiva y codificación categórica, también sin escalamiento. Para K-Means se seleccionaron nueve variables numéricas, se aplicó imputación por mediana y se estandarizaron las escalas. En los modelos supervisados se separaron entrenamiento y prueba antes de ajustar las transformaciones, evitando utilizar información de prueba durante el aprendizaje.

Modelado. Se implementaron distintas alternativas para responder al problema desde perspectivas complementarias. En clasificación se realizó un experimento binario y se compararon Decision Tree y Random Forest con tres categorías, tanto en versiones base como optimizadas. En regresión se compararon Decision Tree e HistGradientBoosting. Las búsquedas de hiperparámetros utilizaron únicamente los conjuntos de entrenamiento. Para el aprendizaje no supervisado se aplicó K-Means y se exploraron distintas cantidades de grupos. Se seleccionaron cuatro segmentos considerando el método del codo, la silueta y la interpretación de los perfiles. PCA se utilizó posteriormente como apoyo para visualizar la estructura de los datos.

Evaluación. Se comparó el desempeño de los modelos y se interpretaron sus errores en relación con el negocio. En clasificación se utilizaron accuracy, precision, recall, F1 y matrices de confusión, prestando especial atención a la categoría alta. En regresión se

revisaron MAE, R^2, predicciones y residuos, destacando HistGradientBoosting optimizado por su menor error promedio. En segmentación se analizaron separación, tamaños y características de los grupos, reconociendo que existe superposición entre ellos. También se compararon resultados de entrenamiento y prueba para identificar sobreajuste y se consideraron limitaciones éticas, como reproducir patrones de exposición histórica o excluir estilos menos representados.

Despliegue. Esta fase se abordó como preparación para una posible aplicación futura. Se generaron informes, se exportaron modelos, transformaciones y resultados para facilitar su reutilización. No se implementó una solución conectada a Spotify ni se midió su impacto real en usuarios o campañas. De esta manera, el trabajo entrega una base analítica para continuar el proyecto, sin presentar la evaluación del dataset como una validación comercial definitiva.

Modelos Implementados; Métricas e Interpretaciones

El proyecto implementó modelos de clasificación, regresión y segmentación para estudiar la popularidad de las canciones desde perspectivas complementarias. La clasificación identifica niveles de popularidad; la regresión estima el puntaje numérico; y la segmentación descubre perfiles musicales similares. Cada enfoque se evaluó con métricas acordes con su propósito, interpretando los resultados como apoyo para seleccionar y analizar canciones, sin asumir que una predicción favorable garantiza éxito comercial.

Clasificación de popularidad

Se compararon Decision Tree y Random Forest, tanto en sus versiones base como optimizadas, utilizando tres categorías: baja, de 0 a 24 puntos; media, de 25 a 49; y alta, de 50 a 100. El accuracy permitió medir los aciertos totales, mientras que precision, recall y F1 macro resumieron el desempeño dando la misma importancia a cada categoría. Este promedio es relevante ante el desbalance de clases, aunque para el objetivo del negocio se revisaron especialmente las métricas de popularidad alta.

Decision Tree base obtuvo una accuracy de 62,44 % y un F1 macro de 0,6104. Su versión optimizada aumentó estos resultados a 64,28 % y 0,6261. La optimización también redujo la diferencia entre entrenamiento y prueba: el F1 macro pasó de 0,9930 en entrenamiento y 0,6104 en prueba para el árbol base, a 0,7836 y 0,6261 para el optimizado. Esto indica una disminución del sobreajuste, aunque el rendimiento todavía depende de qué canciones se utilicen para aprender y evaluar.

La mejora general del árbol optimizado no se trasladó a una mayor detección de canciones altas. El recall de esa categoría disminuyó de 50,52 % a 49,13 %, mientras que su precision aumentó de 52,46 % a 55,47 %. Por tanto, el árbol optimizado realizó selecciones como altas proporcionalmente más confiables, pero dejó escapar una mayor cantidad de

canciones realmente altas. Este resultado demuestra por qué no basta con elegir un modelo únicamente por su accuracy o F1.

Random Forest obtuvo mejores resultados generales que los árboles individuales. Su versión base alcanzó una accuracy de 71,11 % y un F1 de 0,6955; la optimizada obtuvo 71,16 % y 0,7027. La accuracy prácticamente no cambió, pero sí se produjo una diferencia importante en la categoría de interés: el recall de alta aumentó de 54,22 % a 64,47 %, mientras que la precision disminuyó de 68,29 % a 62,99 %. El F1 de alta mejoró de 0,6045 a 0,6372, reflejando un mejor equilibrio entre detección y selección correcta.

La matriz de confusión permite traducir estos porcentajes a cantidades concretas. De las 4.242 canciones realmente altas del conjunto de prueba, Random Forest optimizado identificó correctamente 2.735, clasificó 1.003 como medias y 504 como bajas. En consecuencia, detectó aproximadamente 64 de cada 100 canciones altas y dejó pasar alrededor de 36. Por otra parte, seleccionó 4.342 canciones como altas, de las cuales 1.607 pertenecían realmente a baja o media. Su precision indica que aproximadamente 63 de cada 100 selecciones como altas fueron correctas.

Frente a Random Forest base, la optimización permitió recuperar 435 canciones altas adicionales, pero generó 539 selecciones incorrectas adicionales como altas. Este intercambio favorece el objetivo de encontrar más canciones del grupo de interés para una revisión posterior. Por ello, se seleccionó Random Forest optimizado como la alternativa más adecuada para la detección inicial.

También se realizó un experimento con Decision Tree binario, separando popularidad baja entre 0 y 33 puntos y alta entre 34 y 100. Obtuvo una accuracy de 75,05 %, precision de 75,18 %, recall de 74,31 % y F1 de 0,7474. Sin embargo, estos resultados no permiten afirmar que sea superior a los modelos multiclase ya que resuelve una tarea más simple y utiliza una definición diferente de alta popularidad. Su utilidad fue experimental, mientras que las tres categorías ofrecen una distinción más detallada para el negocio.

Estimación del puntaje mediante regresión

En regresión se compararon Decision Tree e HistGradientBoosting, en versiones base y optimizadas. El indicador principal fue MAE, que expresa cuántos puntos de popularidad se aleja, en promedio, la estimación del valor real. Se complementó con R^2, que indica qué proporción de la variación de popularidad consigue explicar el modelo. Un MAE menor y un R^2 mayor representan mejores resultados dentro de esta comparación.

Decision Tree base obtuvo un MAE de 15,81 puntos y un R^2 de 0,10. Después de optimizarlo, el error disminuyó a 11,82 puntos y el R^2 aumentó a 0,31. HistGradientBoosting base alcanzó un MAE de 11,78 y un R^2 de 0,37, mientras que su versión optimizada obtuvo el mejor resultado: MAE de 11,15 puntos y R^2 cercano a 0,40.

El MAE de 11,15 significa que las predicciones se desviaron, en promedio, aproximadamente once puntos del puntaje real. No significa que todas las canciones tengan ese error ni que exista un margen garantizado de once puntos. Asimismo, R^2 de 0,40 indica que el modelo explica aproximadamente el 40 % de la variación observada en prueba, no

que acierte el 40 % de las canciones. Los resultados muestran capacidad predictiva parcial, con información relevante sobre popularidad que todavía no logra recuperar.

Se seleccionó HistGradientBoosting optimizado por combinar el menor error promedio y el mayor R^2 de las alternativas evaluadas. Para el negocio, puede aportar una estimación orientativa que complemente la clasificación y ayude a explorar el catálogo. Sin embargo, los gráficos de diagnóstico sugieren sobreestimación de algunas canciones con popularidad cero y subestimación de algunos casos altos. Se recomienda revisar el error por rangos de popularidad y género antes de utilizar el puntaje como criterio para priorizar recursos.

Segmentación de perfiles musicales

Se aplicó K-Means sobre nueve características numéricas para descubrir grupos de canciones con perfiles acústicos similares. La popularidad no participó en la formación de los segmentos, sino que se utilizó después para describirlos. Se exploraron distintas cantidades de grupos mediante el método del codo y el coeficiente de silueta, junto con la interpretación de sus perfiles.

La solución de cuatro grupos obtuvo una silueta de 0,1596, mientras que dos grupos alcanzaron 0,2474. Por ello, cuatro segmentos no constituyen la alternativa con mayor separación según esta métrica. Se eligieron como un equilibrio entre la sugerencia del método del codo y la posibilidad de describir perfiles más específicos. El valor de silueta señala que existe superposición entre los grupos, por lo que deben interpretarse como perfiles exploratorios y no como categorías musicales completamente separadas.

El primer segmento reunió 13.870 canciones, equivalentes al 15,46 %, con un perfil más acústico, instrumental y tranquilo. El segundo agrupó 7.277 canciones, el 8,11 %, con mayor presencia de características asociadas a actuaciones en vivo y contenido hablado. El tercero incluyó 29.505 canciones, el 32,88 %, con un perfil rápido, intenso y poco acústico. El cuarto reunió 39.089 canciones, el 43,56 %, caracterizadas por mayor bailabilidad y positividad musical.

Estos perfiles permiten proponer formas de organizar el catálogo: canciones tranquilas para playlists de concentración o relajación; contenido en vivo para explorar actuaciones; canciones intensas para actividades físicas; y canciones bailables para contextos de fiesta o buen ánimo. Estas aplicaciones son hipótesis que deberían validarse mediante datos de escucha, guardados y saltos de canciones. Además, el segundo segmento presenta una mayor concentración de valores extremos, por lo que requiere especial cautela en su interpretación.

La popularidad promedio de los segmentos fue de 29,38, 33,31, 33,83 y 34,06 puntos, respectivamente. Aunque el grupo bailable presentó el promedio más alto, la diferencia respecto de los grupos segundo y tercero es pequeña. No corresponde concluir que ese perfil garantiza mayor éxito ni descartar los demás. La segmentación aporta principalmente contexto musical para realizar estrategias diferenciadas.

Recomendaciones para el negocio

Los resultados respaldan utilizar Random Forest optimizado para una primera identificación de canciones altas, HistGradientBoosting optimizado para estimar su puntaje y K-Means para describir perfiles del catálogo. Los enfoques pueden aportar información complementaria, aunque su uso conjunto todavía no fue evaluado como una solución integrada.

Se recomienda mantener una revisión humana de las canciones seleccionadas, analizar el desempeño por género y perfil musical, y evitar que una predicción baja se convierta en un criterio automático de exclusión. De esta manera, las métricas obtenidas se traducen en decisiones fundamentadas, reconociendo los errores y límites del proyecto.

Matriz de responsabilidades

Responsable	Responsabilidad
Diego Améstica	Análisis exploratorio - Modelo de **Clustering mediante K-Means**
Gino Andrades	Análisis exploratorio - Modelos de **Regresión**
Agustín Cáceres	Análisis exploratorio - Modelos de **Clasificación**